计算机科学与技术学院神经网络与深度学习课程实验报告

实验题目:神经网络的正则化和批归一化 学号: 202020130190

日期: 2022.10.10 班级: 智能 姓名: 刘绪波

Email: 2842353032@gg.com

实验目的:

掌握基本的神经网络的调参技能,并学习如何对神经网络进行改进,如超参数调整,正则化,批量标准化等,本次实验主要完成两个子任务即正则化和批归一化;

实验软件和硬件环境:

软件: Dataspell 2022.2.2;

硬件: CPU: AMD Ryzen 7 4800U; 显卡: AMD Radeon

实验原理和方法:

1. 正则化(Regulation):

正则化,即在成本函数中加入一个正则化项(惩罚项),惩罚模型的复杂度,防止网络过拟合;本实验中采用 12 正则化和 dropout 正则化:

① 对于 L2 正则化:

原理介绍:L2 正则化分为两部分,一部分是在求损失函数的时候,在损失函数后面加一个惩罚项,另一部分是在 backward prop 求偏导时加上惩罚项;

$$J = -\frac{1}{m} \sum_{i=1}^{m} \left(y^{(i)} \log \left(a^{[L](i)}\right) + (1 - y^{(i)}) \log \left(1 - a^{[L](i)}\right)\right) \boxed{1}$$

$$J_{regularized} = \underbrace{-\frac{1}{m} \sum_{i=1}^{m} \left(y^{(i)} \log \left(a^{[L](i)}\right) + (1 - y^{(i)}) \log \left(1 - a^{[L](i)}\right)\right)}_{\text{cross-entropy cost}} + \underbrace{\frac{1}{m} \frac{\lambda}{2} \sum_{l} \sum_{k} \sum_{j} W_{k,j}^{[l]2}}_{\text{L2 regularization cost}} \boxed{2}$$

上面这个图片就展示了从没有正则化到有正则化的公式上的变化;对于 backward prop 中我们只需要考虑到 dW1,dw2,dw3 即可:

$$(rac{d}{dW}\,(rac{1}{2}\,rac{\lambda}{m}\,W^2)=rac{\lambda}{m}\,W)$$

② 对于 dropout 正则化:

dropout (随机失活) 也是一种非常使用的正则化方法; 下面介绍 dropout 的几个步骤:

- 1. In lecture, we dicussed creating a variable $d^{[1]}$ with the same shape as $a^{[1]}$ using np. random. rand() to randomly get numbers between 0 and 1. Here, you will use a vectorized implementation, so create a random matrix $D^{[1]} = [d^{1}d^{[1](2)}...d^{[1](m)}]$ of the same dimension as $A^{[1]}$.
- 2. Set each entry of $D^{[1]}$ to be 0 with probability (1-keep_prob) or 1 with probability (keep_prob), by thresholding values in $D^{[1]}$ appropriately. Hint: to set all the entries of a matrix X to 0 (if entry is less than 0.5) or 1 (if entry is more than 0.5) you would do: x = (x < 0.5). Note that 0 and 1 are respectively equivalent to False and True.
- 3. Set $A^{[1]}$ to $A^{[1]} * D^{[1]}$. (You are shutting down some neurons). You can think of $D^{[1]}$ as a mask, so that when it is multiplied with another matrix, it shuts down some of the values.
- 4. Divide $A^{[1]}$ by keep_prob. By doing this you are assuring that the result of the cost will still have the same expected value as without drop-out. (This technique is also called inverted dropout.)

2. 批归一化(Batch Normalization):

BN 就是在激活函数接收输入之前对数据分布进行规范化,具体计算就是去均值归一化,将数据的分布都规范到标准正态分布中,使得激活函数的输入值落在函数较为敏感的区域,也即梯度较大的区域,从而避免梯度消失、减少训练时间。因此,BN 也通常需要放在激活函数之前。简要来说,我们对输入(N x D)求均值(D)方差(D),然后用均值和方差去归一化我们的整个输入,得到一个输出(N x D)并且我们会保存一个 running_mean 和 running_var,这两个是历史均值/方差目前均值、方差的加权和,这二者只会在训练时计算,测试时直接使用这两个数据对输入数据进行归一化。

实验步骤: (不要求罗列完整源代码)

1. 正则化(Regulation):

主要步骤时先通过实现没有任何正则化过的模型,通过该模型对原数据集进行边界划分,得出结果,然后再实现两种正则化的方法: L2 正则化和 dropout 正则化;随后进行结果比较,观察正则化的必要性和起到的效果;

- ① 首先使用没有经过正则化的模型进行边界划分:此处模型已经给出,并且对每一万次的 迭代都输出一个 cost;最后画出决策边界;
- ② 将模型进行 L2 正则化,关于如何进行 L2 正则化在实验原理部分已经介绍;下面列出 L2 正则化的模型公式和部分关键代码:

```
W2 = parameters["W2"]
W3 = parameters["W3"]

cross_entropy_cost = compute_cost(A3, Y) # This gives you the cross-entropy part of the cost

### START CODE HERE ### (approx. 1 line)
L2_regularization_cost = lambd * (np.sum(np.square(W1)) + np.sum(np.square(W2)) + np.sum(np.square(W3))) / (2 * m)

### END CODER HERE ###

cost = cross_entropy_cost + L2_regularization_cost
```

```
### START CODE HERE ### (approx. 1 line)

dW3 = 1./m * np.dot(dZ3, A2.T) + (lambd * W3) / m

### END CODE HERE ###

db3 = 1./m * np.sum(dZ3, mxiz=1, keepdims = True)

dA2 = np.dot(W3.T, dZ3)

dZ2 = np.multipty(dA2, np.int64(A2 > 0))

### START CODE HERE ### (approx. 1 line)

dW2 = 1./m * np.dot(dZ2, A1.T) + (lambd * W2) / m

### END CODE HERE ###

db2 = 1./m * np.sum(dZ2, axiz=1, keepdims = True)

dA1 = np.dot(W2.T, dZ2)

dZ1 = np.multipty(dA1, np.int64(A1 > 0))

### START CODE HERE ### (approx. 1 line)

dW1 = 1./m * np.dot(dZ1, X.T) + (lambd * W1) / m

### END CODE HERE ###

db1 = 1./m * np.sum(dZ1, axiz=1, keepdims = True)

gradients = {"dZ3": dZ3, "dW3": dW3, "db3": db3,"dA2": dA2,

"dZ2": dZ2, "dW2": dW2, "db2": db2, "dA1": dA1,

"dZ1": dZ1, "dW1": dW1, "db1": db1}
```

③ 将模型进行 dropout 正则化,原理部分有介绍四个步骤,列出 dropout 正则化的部分实现代码:

2. 批量标准化(Batch Normalization):

进行 BN 的算法步骤: 求均值。求方差。对数据进行标准化(将数据规范到标准正态分布)。训练参数 γ 和 β 。通过线性变换输出。

下面看具体实验中的步骤及结果展示:

1. 进行 BN: 代码展示:

下面进行对归一化的结果进行验证:

经过了归一化,样本的均值变为0,方差变为1:结果很好:

2. 进行 backward:

代码展示: batchnorm backward:

结果展示:

dx error: 1.7029235612572515e-09

dgamma error: 7.420414216247087e-13 dbeta error: 2.8795057655839487e-12

代码展示: batchnorm_backward_alt:

结果展示:

dx difference: 1.0733384330935792e-12

dgamma difference: 0.0
dbeta difference: 0.0

speedup: 2.07x

结论分析与体会:

1. 正则化(Regulation):


结果展示:

① 未进行正则化的模型输出:

Cost after iteration 0: 0.6557412523481002

Cost after iteration 10000: 0.16329987525724216

Cost after iteration 20000: 0.13851642423268143




On the training set:

Accuracy: 0.9478672985781991

On the test set:


Accuracy: 0.915

Accuracy



② 经过 L2 正则化的模型输出:


Cost after iteration 0: 0.6974484493131264 Cost after iteration 10000: 0.2684918873282238 Cost after iteration 20000: 0.2680916337127301



On the train set:


Accuracy: 0.9383886255924171

On the test set: Accuracy: 0.93



③ 经过 dropout 正则化的模型输出:


Cost after iteration 10000: 0.0610169865749056 Cost after iteration 20000: 0.060582435798513114



On the train set:

Accuracy: 0.9289099526066351

On the test set: Accuracy: 0.95



由上面可以看出原模型出现了严重的过拟合情况,L2 正则化则对该情况进行了一定程度的避免,而 dropout 效果最好;另外,之所以 L2 正则化能够实现减轻过拟合的情况:如果正则化 λ 设置得足够大,权重矩阵 W 被设置为接近于 0 的值,直观理解就是把多隐藏单元的权重设为 0,于是基本上消除了这些隐藏单元的许多影响。如果是这种情况,这个被大大简化了的神经网络会变成一个很小的网络,小到如同一个逻辑回归单元,这个神经网络就变成了很简单的网络了,所以就避免了过拟合,当然有时候反而会导致了欠拟合。

2. 批归一化(Batch Normalization):

- ① 对于 BN 的设计以及反向传播的结果在上面步骤中已经展现出来;
- ② 对于 BN 的作用的分析: 对数据进行规范化,降低样本之间的差异。使激活函数的输入落在梯度较大的区域,一个很小的输入差异也会带来较大的梯度差异,可以有效的避免梯度消失,加快网络的收敛。降低了层与层之间的依赖关系,不加 BN 的时候当前层会直接接收上一层的输出,而加了 BN 之后当前层接收的是一些规范化的数据,因此使得模型参数更容易训练,同时降低了层与层之间的依赖关系。
- ③ 在训练阶段可以设置更高的学习率,因为 BN 有快速收敛的特性。我们在网络中加入 Batch Normalization 时,可以采用初始化很大的学习率,然后学习率衰减速度也很大, 因此这个算法收敛很快。

3. 对于二者的区别:

- ① BN 是拉平不同特征图(也可以说是特征)之间的差异,进行去均值归一化。而 L2 参数 权重正则化则没有改变同一层参数的相对大小,而是对当前参数自身进行正则化。
- ② 对于一个特征图,它们量级、方差可能都不同,而 BN 就让方差为 1,均值为 0,从而导致特征图之间的差异减小了。L2 参数权重正则化不以此层面为目标产生影响。
- ③ L2 参数权重正则化是对各个参数权重本身的,而 BN 是对特征图全局的。
- ④ L2 参数权重正则化让网络的权重不会过大,而 BN 的主要目的是加快训练同时防止梯度 消失.

就实验过程中遇到和出现的问题, 你是如何解决和处理的, 自拟 1-3 道问答题:

1. 在进行 BN 是出现了报错问题:

然后发现原因是对于前向传播的函数编写不正确, 了正确结果;	从而导致了报错经过对前向传播的函数纠正,	运行出